

Announcement

- 期末考
 - 6/3 (三)14:10 ~ 16:00
 - 地點: 337, 338 (請參考ilearning 公告)
 - 範圍C6~C9
 - No open book
 - 考試開始30分鐘後不得入場
- 第十六週為期末專題週
 - 可至上課教室確認期末考成績和詢問期末專題相關事項

Advanced NLP Tasks

Named Entity Recognition

- Named entity recognition (NER) 讓我們能夠識別 (即標記) 文件中的所有人名、地名和公司名稱。
- 和 parts-of-speech tagging 一樣類型的任務 (many-to-many)

Entities

Steve Jobs was the CEO of Apple , headquartered in the state of California .

PER ORG LOC

NER 的挑戰

- 有些實體會跨越多個詞元(例如 “Steve” 和 “jobs”)
- 同一個詞在不同語境下可能代表不同實體類別(ex: "Apple" 是公司還是水果)
- 中文等語言沒有空格切詞, 斷詞會影響準確性
- 新詞(如新興企業、人名)難以預測
- 資料高度不平衡(大多數詞元都被標記為 “O”)

Token:	Steve	Jobs	really	liked	to	wear	black	turtlenecks.
Tag:	B-PER	I-PER	O	O	O	O	O	O

NER 的挑戰


- 有些實體會跨越多個詞元(例如 “Steve” 和 “jobs”)
- 同一個詞在不同語境下可能代表不同實體類別(ex: "Apple" 是公司還是水果)
- 中文等語言沒有空格切詞, 斷詞會影響準確性
- 新詞(如新興企業、人名)難以預測
- 資料高度不平衡(大多數詞元都被標記為 “O”)

Token:	Steve	Jobs	really	liked	to	wear	black	turtlenecks.
Tag:	B-PER	I-PER	O	O	O	O	O	O

NER 需要結合上下文語意, 這也是 BERT 類模型效果較好的原因之一。

NER 模型演進

1. **傳統模型** : CRF、HMM, 依賴人工特徵 (POS、位置等)
2. **深度學習模型** : BiLSTM + CRF (引入上下文, 但需大量訓練資料)
3. **Transformer-based 模型** : BERT + CRF / linear classifier, 利用 contextual embedding 提升準確率



Conditional Random Field (CRF)

- CRF 是一種機率圖模型，專門設計來預測序列中的標籤(labels)，例如一串句子中每個詞的實體類別。
- 它考慮了：
 - 當前詞的特徵(例如:詞、詞性、是否為大寫)
 - 相鄰標籤之間的關聯性(例如:一個 B-PER 標籤後面不應該接 I-ORG)

Ex: Steve Jobs founded Apple.

- 若只用 softmax 去預測每個詞的標籤，可能會出現這種結果：
 - Steve B-PER
 - Jobs I-ORG ✗
 - founded O
 - Apple B-LOC ✗
- CRF 可以透過建模標籤間的轉換機率，避免這些不自然的標註組合。

Conditional Random Field (CRF)

- CRF 是一種機率圖模型，專門設計來預測序列中的標籤(labels)，例如一串句子中每個詞的實體類別。
- 它考慮了：
 - 當前詞的特徵(例如：詞、詞性、是否為大寫)
 - 相鄰標籤之間的關聯性(例如：一個 B-PER 標籤後面不應該接 I-ORG)

Ex: Steve Jobs founded Apple.

- 若只用 softmax 去預測每個詞的標籤，可能會出現這種結果：
 - Steve B-PER
 - Jobs I-ORG ✗
 - founded O
 - Apple B-LOC ✗
- CRF 可以透過建模標籤間的轉換

簡單類比：

- 如果只用 softmax, 模型是「逐字猜標籤」, 每次獨立決定;
- 如果用 CRF, 模型會「整體考慮」, 在所有可能的標籤組合中找出最合理的一條序列。

BIO Format

- B: 實體的開頭 (Begin)
- I: 實體的內部 (Inside)
- O: 非實體 (Outside)

Steve	Jobs	was	the	CEO	of	Apple	headquartered	in	Silicon	Valley
B-PER	I-PER	O	O	O	O	B-ORG	O	O	B-LOC	I-LOC

NER 評估方式

- Precision, Recall, F1 score
- Token-level vs Entity-level
 - Token-level: 對每個 token 的標註是否正確來評估(較寬鬆)
 - Entity-level: 需整個實體類別與邊界都正確, 才算 TP(較嚴格、常用)
 - 範例: 若實體是 New York City, 預測成 New York 就不算正確(Entity-level)

NER 為何重要以及延伸應用

- **NER 是資訊抽取任務的核心**

- 資訊抽取 (Information Extraction) = 從大量文本中找出有用資訊
- NER 就是這一步的基礎工作, 讓非結構化文字轉為 **結構化資料**

- **範例:**

- 新聞原文: Tesla plans to build a new factory in Monterrey, Mexico by 2026.
- NER 輸出:
 - Tesla → ORG
 - Monterrey → LOC
 - Mexico → LOC
 - 2026 → DATE

- **可接續應用: 關係抽取、知識圖譜建構、文件分類...**

NER 為何重要以及延伸應用

- 有些高階 NLP 任務仰賴 NER 輸出
- 問答系統
 - 判斷提問中要查詢哪種實體
- 對話系統
 - 判斷地點、人名以觸發回應
- 自動摘要
 - 擷取重要實體決定保留內容
- 法律/醫療分析
 - 辨識人名、藥物、疾病名稱
- 金融監控
 - 找出公司、交易對象、時間地點

NER 為何重要以及延伸應用

- 有些高階 NLP 任務仰賴 NER 輸出
- 問答系統
 - 判斷提問中要查詢哪種實體
- 對話系統
 - 判斷地點、人名以觸發回應
- 自動摘要
 - 擷取重要實體決定保留內容
- 法律/醫療分析
 - 辨識人名、藥物、疾病名稱
- 金融監控
 - 找出公司、交易對象、時間地點

當然也可以直接透過生成式 AI 一步到位，
但使用 NER 作為 filter 可以提升效率以
及達到特定需求

NER 為何重要以及延伸應用

NER 是**可擴展**的, 不只是人名地名！NER 可以擴展為：

- Fine-grained NER: 像是產品、貨幣、學術領域
- Domain-specific NER: 法律、醫療、金融的專用實體
- Nested NER: 一個實體內部還有另一個實體 (如: University of California, Berkeley)

Natural Language Inference (NLI)

- **Natural Language Inference (NLI)**, 又稱為 **Recognizing Textual Entailment (RTE)**
- 目標:判斷兩個句子之間的邏輯關係。
 - Premise(前提):給定的一個句子
 - Hypothesis(假設):需要檢驗的句子
- 三種典型的關係:
 - **Entailment**(蘊涵):前提必然導致假設為真。
 - **Contradiction**(矛盾):前提與假設互相矛盾。
 - **Neutral**(中立):前提與假設無明顯蘊涵或矛盾關係。

Example

Premise	Hypothesis	Label
A man is playing a guitar.	A man is making music.	Entailment
A man is playing a guitar.	A man is sleeping.	Contradiction
A man is playing a guitar.	A man is performing on stage.	Neutral

NLI 挑戰

- **語意理解的細節非常重要(不只是單字比對)**

- Premise: The boy is running a race.
- Hypothesis: The boy is jogging casually.
- 表面上 "running" 和 "jogging" 類似, 但實際語意不同。"Race" 暗示競賽、快速, "jogging" 則是輕鬆慢跑。
- 標記: **Contradiction**

- **背景知識 (common sense) 常常是必要的**

- Premise: A man is buying a ticket at the cinema.
- Hypothesis: The man is going to watch a movie.
- 前提沒明講「要看電影」, 但常識推論「買電影票 → 看電影」。
- 標記: **Entailment**

NLI 挑戰

- **同義詞、上下文推理**

- Premise: The child is eating a sandwich.
- Hypothesis: The kid is having lunch.
- "child" = "kid" 是同義詞, "eating a sandwich" 很可能是吃午餐, 需結合語境推理。
- 標記: **Entailment** 或 (如果太寬鬆, 也可標 **neutral**)

- **否定詞、雙重否定等語言現象**

- Premise: No one in the room was unaware of the problem.
- Hypothesis: Everyone knew about the problem.
- "No one unaware" = "Everyone aware", 必須正確解析雙重否定。
- 標記: **Entailment**

常見資料集

Dataset	特點	難度
SNLI	單一領域、簡單句子	低
MNLI	多領域、正式與口語兼有	中
ANLI	人工設計出容易讓模型出錯的句子關係 Ex: 假設一個模型很容易認為「有相同主詞就代表蘊涵」 Premise: A dog is running outside. Hypothesis (annotator寫的對抗例子): A dog is sleeping peacefully inside the house. → contradiction	高

NLI 方法

- BERT

- 雙向 Transformer 預訓練, 然後微調
- 微調方法:
 - 把 premise 和 hypothesis 用 [SEP] 分開, 一起餵進 Transformer
 - [CLS] token 的向量拿去做三分類 (entailment/neutral/contradiction)

- RoBERTa

- 改進版的 BERT
- 對 NLI:
 - 在 MNLI 上微調後能顯著提升泛化到其他領域的能力。

NLI 方法

- DeBERTa (Microsoft)
- 核心創新：
 - 相對位置編碼 (relative position encoding)
 - 分離的內容與位置注意力 (disentangled attention)
 - BERT: $\text{attention}(\text{content} + \text{position}) \rightarrow$ 可能混淆內容與位置的貢獻 (例如:「狗追貓」和「貓追狗」)
 - DeBERT: $\text{attention}(\text{content}) + \text{attention}(\text{position}) \rightarrow$ 更細緻
- 在 NLI 上特別強, 尤其是需要細膩推理 (例如 ANLI) 時, 優於一般 BERT。
- DeBERTa-large 幾乎在 MNLI、ANLI 上都接近人類水準。

NLI 方法

- T5 / mT5 / Flan-T5
- 把 NLI 當作一個文字生成任務
 - 輸入: "premise: ... hypothesis: ..." → 直接生成 "entailment" / "neutral" / "contradiction"。
- Flan-T5 加了 instruction tuning, 效果更好。
 - 訓練資料從「輸入內容 → 輸出答案」變成「指令 + 輸入內容 → 輸出答案」
 - "Translate English to German: The house is small." → "Das Haus ist klein."
 - "Summarize this paragraph:" → [段落的摘要]
 - "Given premise and hypothesis, predict NLI label:" → "entailment"
- 多語言版: mT5, 支援跨語言 NLI。

Text Summarization

- Text Summarization是指：自動地將一段長文本，縮短成一段簡潔、保留重點的內容。
- Extractive Summarization：從原文中**挑選**關鍵句子，組成摘要。
- **Abstractive Summarization**：**重新理解並用自己的話寫出摘要，像人類一樣重組、改寫。**

Abstractive Summarization

- 抽取式摘要的局限：
 - 只能簡單剪貼原文，無法進行深入整合。
 - 缺乏自然的表達，句子銜接生硬。
- Abstractive 的優勢：
 - 能夠理解原文意涵，重新組織與精煉資訊。
 - 可以融合多句內容，寫出流暢、自然的新句子。
- 應用場景更廣泛：
 - 需要高度語意理解與自然生成的場合，如新聞、自動報告、聊天機器人回答等。

Abstractive Summarization 的代表模型

- 基礎架構: Transformer
- Seq2Seq 預訓練模型: BART, T5
- 摘要特化型模型: PEGASUS
- 通用大模型 (Zero/Few-shot 摘要): UL2, GPT-3.5/GPT-4

PEGASUS

- 設計目的：
 - 專門為自動摘要任務打造的預訓練模型
 - 由 Google Research 在 2020 年提出
- 核心想法：
 - 在預訓練階段，故意刪除 (mask) 一段關鍵句子
 - 讓模型學會理解整篇文章並重建缺失內容
 - 這種方式模擬了生成摘要的行為
- 預訓練方法：
 - 名為 **Gap Sentence Generation (GSG)**
 - 不是隨便遮蓋單詞，而是遮蓋資訊密度最高的句子
 - 目標：學會「閱讀整篇→理解→用自己的話補上重點」

Gap Sentence Generation (GSG)

- 不是學單字層級的修補，而是學內容層級的重建
- 流程：
 1. 讀取一篇完整的原始文本
 2. 分析文本中每個句子的 **資訊密度**
 - a. 以統計方法(例如句子的 TF-IDF 分數、位置特徵)來判斷哪些句子資訊含量高
 - b. 資訊密度高的句子通常就是摘要該選取的內容(如主題句、關鍵事實)
 3. 遮蔽這些高資訊量句子
 4. 讓模型學習：從缺失的文章中生成這些被刪除的重要句子
 - a. 輸入：刪除關鍵句後的殘缺文章
 - b. 輸出：原本被刪除的重要句子
 5. 自動指標 (如 ROUGE、BERTScore) + 人工評估 (Fluency、Coverage、Faithfulness)

Example

- 原始文本：**全球暖化導致極端天氣事件頻繁發生。各國政府正在制定新的氣候政策以應對挑戰。專家建議投資再生能源。**
- GSG操作步驟：
 1. 資訊密度分析：發現「**全球暖化導致極端天氣事件頻繁發生**」是關鍵句
 2. 遮蔽關鍵句：拿掉這句，只留其他內容
 3. 輸入模型的文本：
 - **各國政府正在制定新的氣候政策以應對挑戰。專家建議投資再生能源。**
 4. 模型要學會生成的內容（目標輸出）：
 - **全球暖化導致極端天氣事件頻繁發生。**
 5. 評估

PEGASUS 的特色與優勢

- 高度針對摘要任務設計，效果比一般預訓練模型更好
- 訓練過程更貼近摘要行為，理解與重組能力更強
- 在多個摘要資料集(CNN/DailyMail、XSum等)上，表現超越當時其他模型
- 同時可以應用於多種語言(經微調後適應多語言摘要)

一篇新聞中，會把最關鍵的一句遮掉，讓模型 **自己寫出那句**，像是在訓練它總結重點。

UL2 — Unified Language Learning

- 由 Google 在 2022 年發表
- 設計目的：
 - 打破單一預訓練方式的限制
 - 同時支持 **理解(encoding)** 和 **生成(decoding)** 兩種能力
- 核心想法：
 - **Mixture-of-Denoising-Objectives** (多種降噪任務混合訓練)
 - 模型在預訓練時, 同時學會：
 - Masked Language Modeling (BERT式)
 - Next Token Prediction (GPT式)
 - Span Corruption (T5式)
- 讓模型在**不同類型任務下**都能表現良好(分類、摘要、問答、生成任務都OK)

Mixture of Denoising Objectives

整體流程

1. 從預訓練資料庫中隨機取一段文本
2. 隨機選擇一種目標任務 (MLM / NTP / SC)
 - a. 根據設定的機率分佈, 有些版本是均勻隨機, 有些微調過
3. 根據選中的任務類型, 對文本做對應的破壞
4. 將破壞後的文本餵給模型, 訓練模型學會復原或生成正確的內容

Example

「科學家在火星上發現了新型微生物，這可能改變我們對生命起源的理解。」

- 遮蔽單字:「科學家在 [MASK1] 上發現了新型微生物，這可能改變我們對 [MASK2] 起源的理解。」
- 模型任務:預測 [MASK1] 是「火星」、[MASK2] 是「生命」。

MLM

- 輸入:「科學家在火星上發現了新型微生物，這可能改變我們對生命」
- 模型任務:預測接下來要生成的詞是「起源的理解」。

NTP

- 遮蔽片段:「科學家在 [MASK1], 這可能 [MASK2]。」
- 模型任務:生成 [MASK1]:「火星上發現了新型微生物」; [MASK2]:「改變我們對生命起源的理解」。

SC

UL2 的特色與應用

- **高度彈性**：理解任務、生成任務皆適用
- **Prompt-based Learning強化**：可以接受各種prompt設計，更容易做 Few-shot/Zero-shot應用
- **學習更全面**：預訓練目標涵蓋了不同語言建模任務，比單一目標更健壯
- UL2 技術也被運用在後來的 PaLM 2(Google大模型) 中，屬於未來大型模型趨勢之一

Example

	PEGASUS	UL2
輸入	全球多個國家近期因極端高溫而發布了熱浪警告。專家指出，氣候變遷導致極端氣候事件頻率增加。世界衛生組織也呼籲各國政府加強應對措施，以減少高溫帶來的公共健康威脅。	summarize: 全球多個國家近期因極端高溫而發布了熱浪警告。專家指出，氣候變遷導致極端氣候事件頻率增加。世界衛生組織也呼籲各國政府加強應對措施，以減少高溫帶來的公共健康威脅。 (Prompt)
輸出	氣候變遷加劇熱浪，各國需加強公共健康應對。	隨著氣候變遷導致極端高溫頻發，各國被呼籲加強應對措施以保障公共健康。
特點	● 簡潔有力，只保留 最關鍵資訊。 ● 語言自然，像人類寫的摘要。 ● 把原文多個句子的重點融合成一句話。	● 仍保留完整背景（氣候變遷 → 熱浪 → 政府應對）。 ● 更重視 邏輯銜接 與資訊完整性。 ● 可以靈活處理較長、較複雜的任務。

Machine Translation

- MT是指將一種語言的文字，自動翻譯成另一種語言的技術
- 核心目標：保留語意、符合語法、流暢自然
- 注意事項
 - Semantic Accuracy
 - 翻譯不能改變原文真正的意思
 - Fluency
 - 翻譯的句子需要符合目標語言的自然表達，而非直譯
 - Terminology Consistency
 - 專有名詞、技術術語必須一致且正確
 - Cultural Appropriateness
 - 文化特有表達要做適當調整，避免直譯錯誤
 - Handling Long or Complex Sentences
 - 需要能跨越多個子句正確理解結構

主要難點

- Word Order Differences
 - 不同語言的主詞、動詞、受詞順序常不同, 需要重新組織句子
- Ambiguity & Context Dependence
 - bank → 銀行 or 河岸
- Long-Distance Dependencies
 - 遠距離詞語之間存在依賴關係, 例如英語關係子句、德語動詞尾置現象
 - Ex: The **book** that the teacher who arrived yesterday recommended **is** very interesting.
- Low-Resource Languages
 - 資料量少的語言翻譯困難, 容易導致模型欠佳
- Style and Emotion Transfer
 - I can't believe you did this!
 - 我真不敢相信你竟然做了這種事! (憤怒)
 - 我真的不敢相信你會這麼做! (驚訝)

MT 方法

- 預訓練-微調
 - 先在大規模無標記資料上預訓練, 然後針對特定語言對微調
 - 範例: mBART、MASS
- 多語言機器翻譯
 - 訓練一個模型同時處理多個語言
 - 代表作: M2M-100, NLLB-200
 - 特點: 直接跨語言翻譯, 支援低資源語言

MT 方法

- 知識蒸餾與輕量化
 - 壓縮大型翻譯模型，讓翻譯系統可以在手機、邊緣裝置上運作
 - 範例：TinyMT、Distilled Transformer
- 生成式AI
 - 新興趨勢：使用大型語言模型（如 GPT、Gemini）處理翻譯，尤其在極少量學習（Few-shot/Zero-shot）場景有潛力

mBART vs BART

mBART $\neq$ BART + multilingual data

- 訓練語言數量不同
 - BART: 只訓練英文
 - mBART: 一次訓練了25種語言(第一版, 後來還有更多版本), 而且這些語言共享一個共同詞彙表
- 詞彙表設計不同
 - BART:
 - 使用標準的英文 Byte-Pair Encoding (BPE) 分詞器
 - mBART:
 - 使用多語言BPE (Multilingual BPE), 設計時讓不同語言能共用同一套 subword units (i.e. 一個**超大共通字典**, 不管拿哪一種語言來, 都可以對應到這個字典裡的子詞)
 - Ex: 這個 model 的 performance 真的非常 impressive
 - 當模型學會一種語言, 就能幫助理解另一種語言

mBART vs BART

- 訓練資料破壞方式略有不同
 - BART:
 - 會做各種破壞：隨機遮蔽、刪除字元、打亂字順、句子遮蔽等等
 - mBART:
 - 強調 span masking (遮蔽連續片段)，更接近翻譯任務中所需要的 **無中生有** 與 **長度伸縮** 能力，以及常遇到的 **資訊缺失** 情境 (例如日文經常省略主詞)
- 輸出方式上額外加入了 **語言ID標籤**
 - BART:
 - 輸入和輸出都只是一般句子
 - mBART:
 - 在每個輸入序列的最開頭加入一個 **語言ID token** (例如 <zh>、<fr>)，提示模型這是什麼語言的資料，且目標語言也用語言 ID 提示，避免模型錯亂

M2M-100

- M2M-100 是由 Facebook AI (Meta AI) 在 2020 年提出的一個多語言機器翻譯模型。

Traditional approach

中文 → 英語 → 法語

問題: 會累積兩次翻譯誤差, 而且中間語意容易扭曲。

M2M-100

- M2M-100 是由 Facebook AI (Meta AI) 在 2020 年提出的一個多語言機器翻譯模型

Traditional approach

中文 → 英語 → 法語

問題: 會累積兩次翻譯誤差, 而且中間語意容易扭曲。

M2M-100

中文 → 法語
日語 → 西班牙語
斯瓦希里語 → 越南語

- 減少誤差
- 翻譯更準確
- 支援更多弱勢語言直接互譯

技術設計

- 資料收集

- 直接收集 **任意語言對** 的資料, 不只是中英、英法這種熱門語言對
- 使用 **自動對齊** (bitext mining) 技術, 例如 LASER embeddings

- 模型架構

- 基於大型 Transformer 架構
- 統一詞彙表, 支援多語言
- 使用語言標籤告訴模型輸入與輸出語言是什麼

- 訓練方式

- 以 source-target pairs 直接訓練, 不經 pivot language (e.g. English)
- 針對低資源語言, 利用 Back-translation 結合單語資料來進行資料擴增

Bitext Mining

- 在訓練機器翻譯模型時，我們需要大量的**平行語料**(bitexts)

問題：

- 世界上很多語言根本沒有那麼多人工對齊的資料
- 想靠人工整理所有語言對的翻譯資料，太貴也太慢

所以就出現了bitext mining的概念，也就是：

- 從大量未對齊的多語語料中，自動找出彼此是翻譯對應的句子

LASER Embeddings

LASER(Language-Agnostic SEntence Representations)是 Facebook 開發的一種多語言句子向量表示法, 它有兩個關鍵特性:

- 跨語言對齊:
 - 同一個意思的句子, 即使語言不同, 它們的向量會靠得很近
 - 例:
 - "I love you"(英文)
 - "Je t'aime"(法文)
 - "我愛你"(中文)
 - 在 LASER 的向量空間裡, 這三句的 embedding 會在附近
- 單一 encoder, 支援多語言:
 - 使用一個共享的 BiLSTM encoder, 可同時編碼90多種語言, 得到語言無關的句子向量

LASER Embeddings

- 訓練目標: 多國語言 → 單一語言
 - 把這 90 多種語言, 全部翻譯成英文
- 架構設計
 - 共用詞彙表 + BiLSTM Encoder + Max-Pooling + Decoder
 - BiLSTM 讀完一個長短不一的句子後, 會透過 Max-pooling 操作, 將整句話壓縮成一個固定長度 (1024 維) 的單一向量 (Sentence Embedding)
- 訓練方式
 - 不告訴 Encoder 語言種類
 - 不給予語言 ID 標籤
 - 只看單一向量進行翻譯
 - Decoder 被設計成無法去偷看 Encoder 每個字節的細節 (不使用 attention)

Bitext Mining 如何進行

1. 準備一堆未對齊的多語言句子(大量網頁爬文資料)
 - a. 假設你有一份中文語料 + 一份西班牙語語料, 但不確定哪些句子是翻譯關係。
2. 用 LASER 把每句話編碼成向量
3. 對這些向量進行 Nearest Neighbor Search
 - a. 比如從每一句中文句子, 找出在西文語料中最像的句子。
4. 套用 Similarity Threshold 或雙向檢查(例如 mutual nearest neighbors)
 - a. 如果中句 A 的最近鄰是西句 B, 且 B 的最近鄰也是 A, 就認為它們可能是 翻譯對句

Back-translation

利用現有的「弱勢到強勢」模型，自己創造出「強勢到弱勢」的訓練資料

- Step 1: 現有模型 (Target → Source)
 - 勉強能把斯瓦希里語 (弱勢)翻成英語 (強勢)的初始小模型
 - 相對簡單，重點在理解
 - 就像中文母語者，英文翻成中文相對簡單
- Step 2: 生成偽資料
 - 收集網路上大量的純英語資料
 - 丟進步驟 1 的模型，讓它硬翻成斯瓦希里語
 - 得到了帶有些微瑕疵的「合成斯瓦希里語 → 真實英語」
- Step 3: 反向訓練
 - 將真實英語作為輸入，合成斯瓦希里語作為目標，去訓練一個「英語 → 斯瓦希里語」的模型
 - 相對困難，重點在生成
 - 就像中文母語者，中文翻成英文相對困難

Semantic Similarity / Paraphrase Detection

- 語意相似度 (Semantic Similarity)
 - 判斷兩個句子或片語在語意上是否相近。
 - 分數型輸出 (如 0 ~ 1)
- 同義句辨識 (Paraphrase Detection)
 - 判斷兩個句子是否為同義句。
 - 分類型輸出 (是 / 否)
- 應用範例
 - 問答系統的相似問句合併
 - 自動改寫檢測 (如學生作業剽竊)
 - 客服聊天紀錄比對與歸類
 - 多語翻譯後的一致性評估

傳統方法

- TF-IDF + cosine similarity
- Word embeddings (Word2Vec, GloVe) + cosine similarity
- 雖然簡單，但難以處理語意變化與語序差異

進階方法

- Bi-Encoder 架構

- 結構: 兩個共享參數的編碼器, 分別編碼句子, 再進行相似度計算 (如 Cosine similarity)
- 常見編碼器: LSTM、BERT
- 常見作法:
 - SBERT: 在 BERT 上加入 pooling 或全連接層進行句子向量建構
 - SimCSE: 透過對比學習 (contrastive learning) 優化語意嵌入
- 優點: 可離線預先編碼句子, 適合用於語意檢索與相似度比對任務

- Cross-Encoder 架構

- 將句子 A、B 一起作為一組輸入 ([CLS] Sentence A [SEP] Sentence B), BERT 一次性處理
- 透過 [CLS] 的向量進行分類, 模型可考慮句子間交互資訊
- 優點: 分類精度高, 適合同義句判斷、NLI 等任務
- 缺點: 無法離線建 embedding, 推論速度慢

Bi-Encoder 架構

- 架構核心

- 兩個輸入句子分別輸入相同權重的編碼器 (e.g., BERT 或 LSTM)
- 這些編碼器產出兩個句子的語意向量 (sentence embeddings)
- 最後透過 Cosine Similarity 或 Euclidean Distance 計算兩向量間的相似度

- 特點

- 架構共享參數: 保證輸入句子經過相同的語言處理轉換, 減少偏差
- 可擴展性強: 適用於檢索任務, 可事先建好 embedding 庫進行快速匹配, 不需要重新跑模型
- 不需要 joint input, 句子可獨立預先處理 → 快速比對大量句子

SBERT

- SBERT 特點 (Sentence-BERT)
 - 將 BERT 改造成 Bi-Encoder 架構 (i.e. no joint input)
 - 能將任意長度的句子轉換為固定維度的向量, 可用於:
 - Semantic Search
 - Clustering
 - Multilingual Sentence Matching
 - 可針對特定任務/資料集進行微調
 - 針對 BERT 輸出的各個 Token 向量, SBERT 探討了不同的池化方式 (如取 平均池化、最大池化)
 - 與原始 BERT 相比, SBERT 更適合直接輸出向量做語意比對

SimCSE

- SimCSE (Simple Contrastive Sentence Embedding) 是一種讓模型學習 sentence embedding 的方法，它使用了 Contrastive Learning 的訓練策略
- 無監督版本：
 - 使用“dropout as noise”進行對比學習
 - 同一句子兩次輸入 BERT，僅因 dropout 差異形成正樣本對
 - 負樣本為同一批 mini-batch 內的其他句子
- 有監督版本：
 - 使用 NLI 資料集中的 entailment/similar pairs 作為正樣本，以及 contradiction pairs 作為負樣本
- 優點：
 - **小資源** 環境下效果卓越 (僅需要 dropout 產生 embedding 擾動)
 - **訓練快** (主要依靠 contrastive loss), **泛化性佳** (句子之間的相對語意位置，不是特定任務分類)


Contrastive Learning

讓語意相似的句子向量彼此接近，語意不同的句子彼此遠離

- Anchor: 原始句子 A
- Positive: 與 A 語意相同的句子 (如同一句或同義句)
- Negative: 與 A 不同語意的句子 (如不相關句子)
- 計算 Contrastive Loss, 如 InfoNCE loss

Step 0

Contrastive loss: 2.45



Step 100

Contrastive loss: 0.25



Dropout as Noise

- SimCSE 把「同一句子經過兩次 BERT + dropout」當成語意相同的一對

例如：

- 句子 A = "The cat is sleeping on the bed."
- 第一次經過 BERT(有 dropout) : 得到向量 v1
- 第二次再經過 BERT(有不同的 dropout) : 得到向量 v2
- 這兩個向量 v1, v2 來自**同一句話, 但略有差異**
→ 被視為 **positive pair**
- 而在同一個 batch 裡其他句子的向量 → 被視為 negative pairs

評估指標與模型表現

- Semantic similarity: Pearson / Spearman correlation (prediction vs ground truth)
 - Pearson: 預測值與標註值之間的線性相關性
 - Spearman: 預測值與標註值之間的相對排名一致性
 - 人類和機器的評分標準可能不同, 因此若我們只希望模型覺得最相似的句子, 剛好也是人類覺得最相似的(排名一致), 這時候就適合用 Spearman
- Paraphrase detection: Accuracy, F1-score